

UNIVERSIDAD DE TARAPACÁ
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS



**“Análisis Comparativo de Algoritmos de Aprendizaje
Automático y Arquitecturas Híbridas para el Pronóstico
y Gestión de Riesgo en el Mercado Bursátil Chileno”
(2008–2026)**

Informe de Investigación para optar al Título de Ingeniería Civil Industrial

Alumno:

Ronald Solares Chuquera

Profesor:

Juan Vega Vargas

Arica-Chile

2026

Agradecimientos

Quiero expresar nuestro más profundo agradecimiento al profesor Juan Vega Vargas, por su guía durante las etapas de este trabajo, desde también la formación temprana en las asignaturas de la carrera que contribuyeron de gran manera al desarrollo de este estudio.

Agradecemos también a los profesores del departamento, cuyo compromiso académico y apoyo han sido fundamentales en mi formación, destacando a los profesores Sebastián González Aguilera y Liliana Pedraja Rejas. Finalmente, a mi familia por su respaldo incondicional durante estos largos años de estudio, su paciencia y por brindarme siempre el apoyo necesario cada vez que lo necesité.

Ronald Solares Ch.

Resumen

Este trabajo de investigación presenta un análisis comparativo integral entre modelos econométricos tradicionales, algoritmos de aprendizaje automático (*Machine Learning*) y arquitecturas híbridas avanzadas para el pronóstico direccional y la gestión de riesgo del índice bursátil chileno (IPSA) en el periodo 2008-2026. A diferencia de los enfoques convencionales que utilizan retornos logarítmicos, esta investigación emplea Diferenciación Fraccionaria (FFD) para crear estacionariedad en las series sin eliminar la memoria de largo plazo, un factor crítico en la predictibilidad financiera.

La metodología evalúa el desempeño de modelos econométricos (ARIMAX-EGARCH), algoritmos basados en árboles (Random Forest, XGBoost) y redes neuronales recurrentes (LSTM, BiLSTM), culminando en la implementación de una arquitectura híbrida ARIMA-LSTM diseñada para capturar dinámicas lineales y no lineales de forma simultánea. La robustez de los resultados se procura mediante un protocolo de validación Purged K-Fold con embargo temporal, evitando el sesgo de supervivencia y el *data leakage*. Los modelos son evaluados bajo métricas de desempeño ajustadas al riesgo, incluyendo el *Maximum Drawdown*, además de una simulación de Triple Barrera para la ejecución de estrategias. Los hallazgos apuntan a la viabilidad de un marco técnico optimizado para la toma de decisiones estratégicas en mercados emergentes bajo condiciones de alta volatilidad.

Palabras Clave: Machine Learning, Fractional Differentiation, IPSA, Hybrid Architectures, Risk Management.

ÍNDICE

1 INTRODUCCIÓN.....	5
2. ALCANCES Y LIMITACIONES.....	6
2.1 Alcances.....	6
2.2 Limitaciones.....	6
3 OBJETIVOS.....	7
3.1 Objetivo General.....	7
3.2 Objetivos Específicos.....	7
4 MARCO TEÓRICO.....	8
4.1 Modelos Econométricos Para Series Financieras.....	8
4.1.1 Modelos ARIMA (Box–Jenkins).....	8
4.1.2 Modelos GARCH.....	9
4.1.2.1 EGARCH.....	9
4.2 Modelos de Machine Learning Aplicados a Series Financieras.....	10
4.2.1 Random Forest.....	10
4.2.2 XGBoost.....	11
4.2.3 LSTM.....	12
4.2.3.1 BiLSTM (Bidirectional LSTM).....	13
4.3 Modelos Híbridos.....	13
4.3.1 ARIMA-LSTM.....	14
4.3.2 LSTM-RF.....	14
4.4 Medición y Gestión del Riesgo.....	15
4.4.1 Medidas de Riesgo.....	15
4.4.2 Medidas de Desempeño Financiero.....	15
4.4.2.1 Desempeño Financiero (Sharpe Ratio, STARR).....	16
4.4.3 Método de Triple Barrera.....	17
4.5 Validación Robusta en Finanzas Cuantitativas.....	18
4.5.1 Diferenciación fraccional (Fractional Differencing).....	18
4.5.2 Estrategia de Validación Híbrida (Two-Stage Validation).....	19
4.6 Indicadores Técnicos y Variables de Momentum.....	20
4.7 Determinantes Macroeconómicos del Mercado Bursátil Chileno.....	21
4.7.1 El Precio del Cobre.....	22
4.7.2 Tipo de Cambio (USD/CLP).....	22
4.7.3 Influencia de Mercados Internacionales (S&P 500-FXI).....	22
4.7.4 Tasas de Interés, Riesgo Soberano y ciclo Económico.....	24
5 METODOLOGÍA.....	26
5.1 Procedimiento.....	26
5.2 Diseño de Bancos de Información (Estudio de Ablación).....	29
6 ANÁLISIS DE RESULTADOS EXPERIMENTALES.....	30
6.1 Entorno de Simulación y Condiciones de Mercado.....	30

6.2 Desempeño del Enfoque Econométrico (ARIMAX).....	31
6.3 Evaluación de Arquitecturas de Deep Learning (LSTM y BiLSTM).....	33
6.4 Algoritmos de Ensamble y Reducción de Varianza (Random Forest y XGBoost).....	35
6.5 Evaluación de Arquitecturas Híbridas (ARIMA-LSTM y LSTM-RF).....	37
6.6 Comparativa Final y Discusión de Resultados.....	40
6.6.1 La Confiabilidad del Accuracy.....	41
6.6.2 La Dependencia del Contexto Internacional (El Dominio del Banco Global).....	41
6.6.3 Jerarquía de Arquitecturas frente a Shocks Estructurales.....	41
7 CONCLUSIONES.....	42
8 BIBLIOGRAFÍA.....	44

ÍNDICE DE FIGURAS

Figura 1. Gráfico de Curva de Capital ARIMAX vs Benchmark.....	32
Figura 2. Gráfico de Curva de Capital BiLSTM vs LSTM vs Benchmark.....	34
Figura 3. Gráfico de Curva de Capital RF vs XGB vs Benchmark.....	36
Figura 4. Gráfico de Curva de Capital ARIMA-LSTM vs LSTM-RF vs Benchmark.....	39
ANEXO A: Diagnóstico de Multicolinealidad (Matriz de Pearson.....	49
Figura A.1: Matriz de correlación de Pearson aplicada a las variables transformadas mediante Diferenciación Fraccional (FFD) e indicadores de régimen estacionario.....	49

ÍNDICE DE TABLAS

Tabla 1. Composición de los Bancos de Información.....	29
Tabla 2. Comparación de Modelos con Métricas de Desempeño y Gestión del Riesgo.....	40

1 INTRODUCCIÓN

En los últimos años, el pronóstico financiero y la gestión del riesgo han pasado de los enfoques econométricos clásicos a modelos de Machine Learning y Deep Learning, reflejando lo que Shi (2025) denomina una transformación metodológica centrada en la predicción out-of-sample y la capacidad de generalización. Según Domenteanu, Diaconu y Delcea (2025), la literatura sobre series temporales e AI creció un 23% anual entre 1997 y 2024, destacando la integración de modelos estadísticos (ARIMA, GARCH) con algoritmos como LSTM o XGBoost. Este cambio, impulsado por el aumento de datos y potencia computacional, busca capturar relaciones no lineales en los mercados, aunque en América Latina su adopción sigue siendo incipiente (Karolyi & Van Nieuwerburgh, 2020).

En las últimas décadas, los mercados latinoamericanos han enfrentado alta volatilidad y dependencia de commodities, mostrando vulnerabilidad ante crisis como la de 2008 y el COVID-19 (Corbo & Schmidt-Hebbel, 2013; Filgueira et al., 2020). Iniciativas como el MILA mejoraron la liquidez, aunque también aumentaron la transmisión de volatilidad en periodos críticos (Pérez & Briceño, 2015; Lukanima, Sánchez-Barrios & Gómez-Bravo, 2024).

A nivel estructural, las bolsas siguen dominadas por sectores tradicionales (minería, energía, banca), lo que concentra el riesgo y aumenta la exposición a los ciclos de materias primas (Arouri, 2009). La escasa profundidad de mercado y las asimetrías regulatorias limitan la estabilidad y previsibilidad de los retornos (Krause & Tse, 2016). Factores recientes, como la guerra en Ucrania (2022), intensificaron la conexión entre mercados de acciones, divisas y commodities en la región (Lukanima et al., 2024). Ante ello, la aplicación de modelos híbridos y de aprendizaje automático bajo el enfoque del *fractional differencing*, se presenta como una alternativa prometedora para capturar la complejidad y no linealidad de los mercados emergentes (López de Prado, 2018; Shi, 2025). Específicamente en el caso de Chile, la alta sensibilidad del IPSA a factores macroeconómicos globales y la persistencia de memoria en sus series de precios exigen una transición desde modelos estocásticos rígidos hacia arquitecturas flexibles capaces de optimizar el compromiso entre estacionariedad e información histórica.

2. ALCANCES Y LIMITACIONES

2.1 Alcances

El presente estudio se centra en el desarrollo y evaluación de un marco algorítmico avanzado para el pronóstico direccional y la gestión operativa en el mercado bursátil chileno, utilizando como activo de referencia el índice IPSA. El alcance de la investigación comprende:

- **Periodo Temporal:** Análisis de datos diarios desde 2008 hasta 2026, abarcando ciclos de alta volatilidad como la crisis subprime, el estallido social en Chile y la pandemia del COVID-19.
- **Preprocesamiento Avanzado:** A diferencia de los estudios tradicionales que utilizan retornos logarítmicos, este trabajo alcanza un nivel de precisión superior mediante el uso de *fractional differencing* (FFD), permitiendo mantener la memoria de la serie temporal.
- **Marco Multivariado:** El estudio no se limita al precio histórico, sino que integra variables macroeconómicas nacionales, indicadores de sentimiento global (VIX, S&P 500) y el mercado de commodities (Cobre) para enriquecer el poder predictivo.
- **Gestión de Operaciones:** Se implementó un simulador de Triple Barrera para transformar las probabilidades del modelo en decisiones de ejecución (Compra/Venta/Hold) con gestión de riesgo dinámica basada en volatilidad (EGARCH).

2.2 Limitaciones

- ❖ **Restricción de Instrumentos:** No se consideran derivados financieros (opciones, futuros, *swaps*), el objetivo se restringe a instrumentos de mercado al contado.
- ❖ **Fricción de Mercado:** Para simular un entorno institucional o de corretaje de bajo costo (ej. plataformas *Fintech* contemporáneas), se aplicó una penalización total del 0.16% por operación completa (*round-trip*), englobando tanto comisiones como el deslizamiento de precios (*slippage*).
- ❖ **Resolución Temporal y Trayecto Intradía:** Debido a la restricción de acceso a datos de alta frecuencia históricos para el mercado chileno desde 2008, el estudio se basa en frecuencias diarias (OHLC). Para mitigar el sesgo de resolución temporal (*Time-Resolution Bias*) en días donde el precio cruza tanto el *Take Profit* como el *Stop*

Loss, se aplicó una heurística conservadora que asume la ejecución de la pérdida en primer lugar, procurando que los rendimientos no estén sobreestimados.

- ❖ **Estrategia Unidireccional (Long-Only) e Impacto de Mercado:** El marco simulado se restringe a posiciones largas, limitándose a la preservación de capital (posición en liquidez) durante los períodos de predicción negativa. Esto obedece a las altas barreras de fricción y costos de préstamo de valores en el mercado local. Asimismo, no se evalúa el impacto en el libro de órdenes (Market Impact), asumiendo que el volumen transado no altera el precio de equilibrio observado.
- ❖ **Apalancamiento:** No se incorpora apalancamiento financiero, manteniendo todas las estrategias bajo un esquema de inversión 1:1 para evitar distorsiones en la comparación del desempeño de los algoritmos.
- ❖ **Variables Nominales:** No se evalúan efectos de inflación o riesgo cambiario transversal, ya que el análisis de rentabilidad se realiza en términos nominales según la moneda local del índice.

3 OBJETIVOS

3.1 Objetivo General

Evaluar el desempeño de modelos econométricos, *Machine Learning* e híbridos en el pronóstico direccional y la gestión operativa de riesgo del índice bursátil chileno (IPSA).

3.2 Objetivos Específicos

- Recopilar y preprocesar datos históricos del IPSA y variables exógenas (macroeconómicas, de sentimiento global y técnicas) para el periodo 2008-2026.
- Desarrollar e implementar algoritmos de clasificación direccional, estructurando un estudio por bancos de variables para determinar el impacto predictivo de cada entorno de información.
- Validar la robustez estadística de los modelos mediante protocolos especializados para series de tiempo.
- Simular y evaluar la viabilidad financiera de los pronósticos mediante un esquema de Triple Barrera con bandas dinámicas de volatilidad

4 MARCO TEÓRICO

4.1 Modelos Econométricos Para Series Financieras

Los modelos econométricos han constituido históricamente el pilar del análisis financiero. Los enfoques ARIMA/ARIMAX (Box & Jenkins, 1976) permiten capturar dependencias lineales y componentes deterministas, mientras que el modelo GARCH (Engle, 1982; Bollerslev, 1986) y sus extensiones, como el EGARCH (Nelson, 1991), modelan la volatilidad condicional y los efectos de apalancamiento.

4.1.1 Modelos ARIMA (Box–Jenkins)

El modelo ARIMA (Autoregressive Integrated Moving Average), desarrollado por Box y Jenkins (1976), es un pilar del análisis de series temporales. A diferencia de los modelos de regresión tradicionales, no requiere variables externas y se basa en la propia historia de la serie, permitiendo que los datos “hablen por sí mismos” (Gujarati, 2004). Asume que la serie es un proceso estocástico, donde cada valor depende de los anteriores. Para su correcta aplicación, debe ser estacionaria, es decir, con media y varianza constantes en el tiempo (Tsay, 2013).

El modelo combina tres componentes: autorregresivo (AR), integrado (I) y media móvil (MA), expresado como $ARIMA(p, d, q)$, donde “p” son los rezagos autorregresivos, “d” las diferenciaciones y q los rezagos de medias móviles. Su principal ventaja es la simplicidad y capacidad predictiva, siendo útil para pronosticar precios, tasas o retornos financieros, y puede complementarse con modelos de volatilidad como GARCH o EGARCH.

4.1.1.1 Modelos ARIMAX

El modelo ARIMAX extiende al ARIMA incorporando variables exógenas (X) que influyen en la variable principal, combinando los componentes autorregresivos (usa valores pasados) y de medias móviles con factores externos que mejoran la capacidad predictiva del modelo (Box & Jenkins, 1976). Este modelo mejora la predicción cuando las variables externas están correlacionadas con la serie de interés asumiendo que sean estacionarias o transformadas adecuadamente. En el presente trabajo, las variables exógenas (X) se obtienen mediante modelos ARIMA individuales, permitiendo que el ARIMAX opere con proyecciones coherentes y totalmente autorregresivas.

4.1.2 Modelos GARCH

El modelo GARCH (Generalized Autoregressive Conditional Heteroskedasticity), propuesto por Bollerslev (1986) como extensión del ARCH de Engle, permite modelar la volatilidad condicional de una serie financiera de forma más eficiente, al considerar tanto los errores pasados como la varianza previa. Esto le otorga una mayor capacidad para capturar la persistencia de la volatilidad observada en los retornos financieros.

El modelo refleja fenómenos típicos de los mercados, como la volatilidad agrupada, las colas pesadas y la reversión lenta a la media, rasgos comunes en series financieras. Sus parámetros se estiman mediante máxima verosimilitud, utilizando funciones de densidad Normal o t-Student, siendo esta última más adecuada para datos con colas gruesas (McNeil, Frey & Embrechts, 2015).

4.1.2.1 EGARCH

El modelo EGARCH (Exponential GARCH), propuesto por Nelson (1991), ofrece una versión más flexible del GARCH para capturar la asimetría en los retornos financieros. A diferencia del modelo tradicional, introduce una estructura logarítmica para la varianza condicional y un término que permite reflejar el efecto apalancamiento, es decir, que los choques negativos generan un aumento mayor en la volatilidad que los positivos de igual magnitud.

El uso del logaritmo asegura que la varianza estimada siempre sea positiva sin imponer restricciones adicionales a los parámetros, haciendo del EGARCH un modelo más estable y realista para describir los cambios de volatilidad en los mercados financieros.

Justificación del Doble Rol Estructural del Modelo EGARCH

Es imperativo destacar que el modelo de volatilidad condicional EGARCH no constituye una redundancia metodológica dentro de la investigación, sino que cumple un doble rol estructural ortogonal:

1. **Como Feature Predictivo (Fase de Entrenamiento):** En los bancos de datos (Técnicos e Híbrido), el EGARCH actúa como una variable de entrada escalar. Su propósito aquí es proveer a los algoritmos de *Machine Learning* el "contexto de

régimen" (alta o baja varianza), permitiendo que redes como el LSTM ajusten sus pesos si el mercado entra en pánico.

2. **Como Gestor de Riesgo Dinámico (Fase de Simulación):** En el entorno *Out-of-Sample*, el EGARCH abandona su rol predictivo y se convierte en el motor del dimensionamiento de posiciones. Los valores de volatilidad proyectados dictan la amplitud exacta de los umbrales de *Take Profit* y *Stop Loss* en la simulación. Esta dualidad procura que el modelo evalúe el riesgo con la misma vara con la que fue entrenado, sincronizando la predicción direccional con la gestión de capital.

4.2 Modelos de Machine Learning Aplicados a Series Financieras

El auge del aprendizaje automático ha ampliado el panorama metodológico del pronóstico financiero. Los algoritmos como Random Forest y XGBoost (Chen & Guestrin, 2016; Hastie, Tibshirani & Friedman, 2009) destacan por su capacidad de capturar interacciones complejas y manejar alta dimensionalidad sin requerir supuestos estrictos de distribución. Por su parte, las redes neuronales recurrentes (RNN) y especialmente las LSTM (Hochreiter & Schmidhuber, 1997) son capaces de modelar dependencias temporales prolongadas y no lineales, lo que las hace idóneas para la predicción de retornos financieros (Fischer & Krauss, 2018).

4.2.1 Random Forest

Para el modelado no lineal se empleó el algoritmo Random Forest (Breiman, 2001), cuya arquitectura de ensamblaje (Bagging) permite mitigar la varianza mediante la construcción de múltiples árboles de decisión descorrelacionados. Matemáticamente, la predicción final se define como la moda de las clases emitidas por el bosque en el caso de clasificación direccional, formalmente, la predicción $\hat{y}$ se expresa como:

$$\hat{C}(x) = \underset{c}{\operatorname{argmax}} \sum_{b=1}^B I(T_b(x) = c)$$

I es la función indicadora que evalúa si el árbol *b* predice la clase *c*

B es el número total de árboles

$T_b(x)$ es la predicción del árbol *b* –ésimo

La aleatorización dual, reduce la correlación entre árboles y equilibra el sesgo y la varianza. Según James et al. (2013), este enfoque mejora el rendimiento predictivo frente a modelos lineales, especialmente en contextos no lineales y de alta dimensionalidad, como los financieros. En este ámbito, Random Forest (RF) se ha consolidado como una herramienta eficiente para modelar relaciones no lineales y aislar la señal en series ruidosas. Su robustez ante *outliers*, junto con una buena interpretabilidad y capacidad predictiva, lo posicionan como un modelo base frente a técnicas más complejas como XGBoost o LSTM (Chen & Guestrin, 2016; Rossi & Sekhposyan, 2021).

4.2.2 XGBoost

El modelo XGBoost, desarrollado por Chen y Guestrin (2016), es una versión optimizada del *Gradient Boosting Machine* (GBM) que mejora la velocidad, precisión y generalización mediante técnicas de regularización y paralelización. Aquí se construyen los árboles de forma secuencial, de modo que cada nuevo árbol corrige los errores del anterior. Se minimiza una función objetivo compuesta por dos términos: la pérdida (loss function), que mide el error entre valores reales y predichos, y un término de regularización, que penaliza la complejidad del modelo para evitar el sobreajuste:

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_i(x_i)) + \Omega(f_t)$$

donde $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$, con T como número de hojas, w_j los pesos asociados a cada hoja, γ el parámetro de penalización y λ el coeficiente de regularización L2 (Chen & Guestrin, 2016). El modelo optimiza la función de pérdida mediante una expansión de Taylor de segundo orden, usando gradientes (tasa de cambio del error) y hessianos (curvatura del error) para ajustar las predicciones con rapidez y estabilidad (Hastie, Tibshirani & Friedman, 2009). La predicción final resulta de la suma secuencial de árboles, incorporando técnicas como poda, regularización y paralelización, que mejoran la precisión y evitan el sobreajuste (Malik, Harode & Kunwar, 2020).

4.2.3 LSTM

Las Long Short-Term Memory (LSTM) son RNN diseñadas para aprender dependencias de largo plazo en secuencias y mitigar el *vanishing gradient* mediante celdas de memoria y puertas que regulan el flujo de información (Hochreiter & Schmidhuber, 1997).

Un LSTM consta de tres puertas principales que controlan el flujo de información:

$$(1) \text{ Forget Gate: } f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

$$(2) \text{ Input Gate: } i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \bar{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$$

$$(3) \text{ Cell State Update: } C_t = f_t C_{t-1} + i_t \bar{C}_t$$

$$(4) \text{ Output Gate: } o_t = \sigma(W_o[h_{t-1}, x_t] + b_o), h_t = o_t \tanh(C_t)$$

Aquí, σ es la función sigmoide, $\tanh$ la tangente hiperbólica, W_* los pesos y b_* los sesgos.

Es pertinente destacar una particularidad en la notación de las fórmulas anteriores: las matrices de pesos (W) no portan el subíndice temporal t . Esto responde al principio de pesos compartidos (*Weight Sharing*), donde la red aplica las mismas reglas de transformación a cada elemento de la secuencia temporal.

Mientras que estos pesos son variables y se ajustan dinámicamente mediante *backpropagation* durante la fase de entrenamiento, permanecen estrictamente constantes durante la fase de evaluación o test. En este sentido, lo que se actualiza en cada instante t no es la estructura de conocimiento de la red (W), sino su memoria de trabajo, representada por el estado oculto (H_t) y el estado celular (C_t) al procesar nueva información.

La puerta de olvido decide qué información descartar, la de entrada agrega nuevos datos a la memoria, y la de salida determina qué parte del estado interno se transmite al siguiente paso.

4.2.3.1 BiLSTM (Bidirectional LSTM)

BiLSTM introduce una segunda capa recurrente que recorre la serie en sentido inverso (futuro $\rightarrow$ pasado). Esta estructura permite que la red capture tanto dependencias causales (efectos pasados sobre el presente) como dependencias contextuales (influencia de estados futuros sobre la secuencia observada) (Schuster & Paliwal, 1997; Lim & Zohren, 2021).

BiLSTM consta de dos subredes LSTM paralelas con estados ocultos, que procesan la secuencia en direcciones opuestas.

$$h_t^{\rightarrow} = LSTM_f(x_t, h_{t-1}^{\rightarrow}); h_t^{\leftarrow} = LSTM_b(x_t, h_{t+1}^{\leftarrow})$$

Esta estructura incrementa la capacidad de representación, permitiendo detectar patrones no lineales, retardos variables y puntos de cambio estructural en las series financieras (Lim & Zohren, 2021). En estudios recientes, se ha sugerido que los modelos BiLSTM mejoran la precisión de pronóstico en horizontes cortos y medianos, especialmente en mercados con alta volatilidad o dependencia recíproca entre variables (Domenteanu et al., 2025; Shi, 2025).

Sin embargo, su naturaleza bidireccional plantea un desafío para contextos estrictamente causales, pues el uso de información “futura” podría inducir sesgos de anticipación (*look-ahead bias*) si no se controla adecuadamente (Lim & Zohren, 2021). Por ello, en aplicaciones financieras, el BiLSTM se recomienda principalmente como herramienta de comparación y validación complementaria al LSTM tradicional, más que como sustituto directo.

4.3 Modelos Híbridos

Estos modelos pueden combinar la estructura lineal y la interpretabilidad de los enfoques estadísticos con la flexibilidad de las técnicas de aprendizaje profundo (Kim & Won, 2018; Stempień & Ślepaczuk, 2025).

De acuerdo con Shi (2025), los modelos híbridos evidencian la transición hacia un paradigma de predicción financiera basado en datos, donde la precisión y estabilidad fuera de muestra se vuelven prioritarias. Complementariamente, Lim y Zohren (2021) sostienen que estas arquitecturas simbolizan la síntesis entre el rigor estructural de la econometría y la flexibilidad del aprendizaje profundo, permitiendo capturar patrones residuales, efectos no estacionarios y dependencias de largo plazo. Además, investigaciones recientes refuerzan la

tendencia hacia la diversificación de arquitecturas híbridas y el uso de técnicas de *ensamble* y *wavelets* para mejorar la generalización (Kim & Baek, 2022; Domenteanu et al., 2025).

4.3.1 ARIMA-LSTM

Su propósito es capturar simultáneamente las relaciones lineales y no lineales presentes en las series temporales financieras. Su desarrollo parte del trabajo seminal de Zhang (2003), quien propuso la combinación de modelos autorregresivos integrados de medias móviles (ARIMA) y redes neuronales artificiales (ANN) como una forma de superar las limitaciones inherentes a cada enfoque por separado. En la actualidad, la evolución de esta idea ha derivado en modelos más sofisticados, donde la red Long Short-Term Memory (LSTM) sustituye a la ANN, mejorando la capacidad de aprendizaje secuencial y la persistencia de la memoria a largo plazo (Pandya, Kapoor & Joshi, 2024; Kalange, 2025).

En este modelo, la serie temporal Y_t se descompone en una componente lineal L_t , capturada por el modelo ARIMA, y una no lineal N_t , estimada por la red LSTM:

$$Y_t = L_t + N_t$$

4.3.2 LSTM-RF

El modelo híbrido LSTM–RF combina la capacidad secuencial de las LSTM con la robustez y no-parametricidad de los ensambles de árboles. Se busca capturar tanto las dependencias no lineales como las interacciones estructurales complejas, frecuentes en los mercados financieros caracterizados por alta volatilidad y heterocedasticidad (Henrique, Sobreiro & Kimura, 2019; Kim & Nam, 2025; Yunita et al., 2025).

La arquitectura más habitual es en serie, donde la LSTM actúa como extractor de características temporales (*embeddings*) y el RF como modelo de predicción final. Formalmente:

$$h_t = f_{LSTM}(X_t; \theta_L), \hat{y}_t = f_{RF}(h_t; \theta_R)$$

Donde X_t es la matriz de *features* temporales, h_t el vector latente generado por la LSTM, y $\hat{y}_t$ la predicción del RF.

4.4 Medición y Gestión del Riesgo

4.4.1 Medidas de Riesgo

VaR

Primero, el Value at Risk (VaR) estima la pérdida máxima esperada de una posición o portafolio que no será excedida con un nivel de confianza α en un horizonte temporal determinado. Su expresión general es:

$$VaR_{\alpha, t+1} = -(\mu_{t+1} + \sigma_{t+1} F_Z^{-1}(\alpha))$$

donde μ_{t+1} es la media esperada del retorno, σ_{t+1} la desviación estándar condicional pronosticada y F_Z^{-1} el cuantil de la distribución de residuos. Aunque es ampliamente utilizada, no informa sobre la magnitud de las pérdidas que superan ese umbral, ni cumple la propiedad de subaditividad (McNeil, Frey & Embrechts, 2015).

CVaR

El Conditional Value at Risk (CVaR) o *Expected Shortfall* complementa al VaR al medir la pérdida promedio esperada cuando se excede el umbral de VaR, siendo más coherente en presencia de colas pesadas:

$$CVAR = E[X|X > VaR_{\alpha}]$$

4.4.2 Medidas de Desempeño Financiero

En el desarrollo de sistemas de *Machine Learning* financiero, depender exclusivamente de métricas de evaluación de clasificación tradicional, como la precisión (*Accuracy*), constituye un error metodológico crítico. Un alto porcentaje de aciertos direccionales no se traduce automáticamente en viabilidad operativa debido a la asimetría inherente de los retornos en el mercado: un algoritmo puede poseer una alta tasa de aciertos con ganancias marginales, pero destruir el capital acumulado en un número reducido de operaciones perdedoras de gran

magnitud. Además, las métricas puramente estadísticas ignoran el impacto real de los costos de fricción (comisiones y *slippage*) y la exposición del portafolio a riesgos de cola extrema (*Drawdowns*). Por consiguiente, para validar la utilidad de un modelo predictivo, es imperativo someter sus señales a un entorno de simulación de ejecución y cuantificar su desempeño mediante métricas financieras especializadas. Estas medidas permiten evaluar no solo la rentabilidad bruta obtenida, sino la eficiencia matemática con la que el algoritmo gestiona la volatilidad, penaliza el riesgo asumido y preserva el capital a lo largo de los diferentes regímenes del mercado.

4.4.2.1 Desempeño Financiero (Sharpe Ratio, STARR)

El desempeño de una estrategia financiera puede evaluarse mediante métricas ajustadas por riesgo, que relacionan retorno y volatilidad para medir eficiencia, robustez y significancia estadística (Sharpe, 1966; Bailey & López de Prado, 2014).

Sharpe Ratio (SR) mide la prima de retorno por unidad de riesgo asumido, asumiendo distribución normal de los retornos:

$$SR = \frac{R_p - R_f}{\sigma_p}$$

donde R_p es el retorno del portafolio, R_f la tasa libre de riesgo y σ_p su volatilidad; un Sharpe alto indica una estrategia más eficiente por riesgo asumido.

STARR Ratio (*Stable Tail-Adjusted Return Ratio*) sustituye la volatilidad por una medida de cola (CVaR), ajustando el rendimiento a los riesgos extremos:

$$STARR = \frac{E[R_p - R_f]}{CVaR_\alpha(R_p)}$$

Un valor elevado refleja robustez frente a caídas severas del mercado.

Se prescinde del uso de métricas de clasificación estáticas como *Precision* y *Recall*, dado que el desbalanceo direccional inherente a los mercados financieros (sesgo natural al alza o a la baja) suele inducir a un sobreajuste interpretativo en dichas medidas. En su lugar, la investigación delega la validación de la robustez frente al sesgo de clase al Método de la Triple Barrera. Este enfoque hace que cualquier sesgo hacia la clase mayoritaria sea penalizado operativamente mediante la ejecución de límites de pérdida (*Stop Loss*).

4.4.3 Método de Triple Barrera

En la evaluación de modelos de *Machine Learning* financiero, la conversión de probabilidades direccionales aisladas en trayectorias de rentabilidad real requiere un marco de ejecución dinámico. Para ello, se implementó el Método de la Triple Barrera propuesto por López de Prado (2018), el cual evalúa el éxito de una predicción no solo por la dirección final del precio, sino por su trayectoria intradiaria y el tiempo de maduración de la señal.

Cada vez que un algoritmo emite una probabilidad direccional superior al umbral de confianza ($p > 0.5$), se simula la apertura de una posición larga al precio de apertura del día siguiente (P_0). Inmediatamente, se establecen tres barreras dinámicas ajustadas por la volatilidad condicional diaria (EGARCH) estimada para ese periodo:

1. **Barrera Superior (Take Profit):** Fija el umbral de toma de ganancias. Para permitir una captura de tendencia exigente, se estableció un multiplicador asimétrico $K_{up}=2.0$

$$TP_t = P_0(1 + k_{up} \cdot \sigma_{egarch})$$

2. **Barrera Inferior (Stop Loss):** Establece el límite máximo de pérdida tolerada. Se definió de forma más ajustada con un multiplicador $K_{down} = 1.5$, priorizando la preservación del capital ante falsas rupturas.

$$SL_t = P_0(1 - k_{down} \cdot \sigma_{egarch})$$

3. **Barrera Vertical (Max Hold):** Impone un límite de tiempo a la operación para controlar el costo de oportunidad. Si el precio no cruza las barreras horizontales, la posición se liquida automáticamente al precio de cierre del décimo día ($t=10$).

Justificación Cuantitativa de los Multiplicadores (Escalamiento de Volatilidad): La parametrización asimétrica de las barreras ($K_{up}=2.0$ y $K_{down}=1.5$) y el horizonte temporal ($t=10$) no son arbitrarios, sino que responden a los fundamentos del Movimiento Browniano Geométrico (GBM). Bajo este marco, la volatilidad de un activo no se acumula linealmente, sino que escala en proporción a la raíz cuadrada del tiempo ($\sqrt{t}$). Para una ventana máxima de 10 días, la dispersión máxima esperada del precio es de aproximadamente $\sqrt{10} \approx 3.16$ veces la volatilidad diaria.

Por lo tanto, exigir un *Take Profit* de $2.0 \times \text{EGARCH}$ procura que la meta de ganancias se encuentre cómodamente dentro del rango de excursión estadística natural del activo para ese periodo de dos semanas. Simultáneamente, el *Stop Loss* ajustado a 1.5 impone un ratio de

riesgo-beneficio asimétrico positivo (1:1.33), forzando al algoritmo a cortar rápidamente las pérdidas ante la invalidación de la señal, mientras deja correr las ganancias tendenciales dentro del límite de tiempo establecido.

Manejo del Sesgo de Resolución Intradía y Fricción: El algoritmo de simulación diseñado para esta investigación evalúa el cruce de barreras utilizando los precios máximos (*High*) y mínimos (*Low*) diarios. Para procurar el realismo institucional y mitigar el sesgo de resolución temporal (*Time-Resolution Bias*), el simulador incorpora una heurística pesimista: si en un mismo día el precio cruza tanto el *Take Profit* como el *Stop Loss* (Choque Doble), el sistema asume invariablemente que la barrera inferior fue tocada primero, registrando una pérdida. Adicionalmente, toda operación ejecutada (entrada y salida) asume un costo de fricción transaccional total del 0.16% (comisión institucional más *slippage* estimado), permitiendo que el *Alpha Neto* reportado sea viable en la práctica operativa.

4.5 Validación Robusta en Finanzas Cuantitativas

La validación de modelos financieros requiere protocolos que consideren la dependencia temporal, el solapamiento de datos y los cambios de régimen, ya que las series financieras no son independientes ni idénticamente distribuidas. Aplicar métodos clásicos de validación cruzada puede inducir *overfitting* y resultados artificialmente optimistas. Por ello se utilizan técnicas diseñadas para evitar *data leakage* y permitiendo consistencia temporal y replicabilidad (Bailey et al., 2014; López de Prado, 2018).

4.5.1 Diferenciación fraccional (Fractional Differencing)

Propuesta por Hosking (1981) y difundida por López de Prado (2018), la FFD busca lograr estacionariedad parcial conservando memoria de largo plazo. Generaliza el operador ARIMA $(1 - B)^d$ para valores fraccionarios de d :

$$Y_t^{(d)} = \sum_{k=0}^{\infty} w_k Y_{t-k}, \quad w_k = \frac{r(k-d)}{r(-d)r(k+1)}$$

Esto permite eliminar tendencias sin perder estructura informativa. En este trabajo se aplica como preprocesamiento común para reducir autocorrelaciones y estabilizar la varianza antes del modelado.

4.5.2 Estrategia de Validación Híbrida (Two-Stage Validation)

Dada la naturaleza heterogénea de los algoritmos comparados y la fuerte dependencia serial de las variables financieras, se diseñó un protocolo de validación en dos etapas que respeta la cronología estricta de los datos. Para ello, el conjunto de datos se particionó secuencialmente: un 80% inicial destinado a la optimización y entrenamiento base, y un 20% final reservado exclusivamente para la evaluación fuera de muestra (*Out-of-Sample*).

- A. **Optimización de Hiperparámetros (Purged K-Fold con Embargo)** Para la selección de la arquitectura óptima de los modelos de Machine Learning (LSTM, Random Forest) dentro del 80% inicial, se utilizó Purged K-Fold + embargo bajo una configuración de 3 particiones. Este método permite mitigar las fallas del K-Fold tradicional en finanzas mediante:

Purging (Purga): Se eliminaron las observaciones del conjunto de entrenamiento cuyo horizonte de evaluación se solapaba con el conjunto de prueba, aplicando una ventana de purga de 60 días (equivalente al *look-back period* del modelo).

Embargo: Se aplicó una franja de exclusión de 10 días posteriores al conjunto de prueba para aislar la correlación serial y evitar que la información tardía contamine el entrenamiento subsiguiente. Este diseño garantizó que los hiperparámetros seleccionados fueran robustos, mitigando el riesgo de *overfitting* y eliminando el sesgo de anticipación (*look-ahead bias*).

- B. **Evaluación Comparativa (Expanding Window Walk-Forward)** Para la comparación final entre el mejor modelo econométrico (ARIMAX) y el mejor modelo de ML en el 20% reservado, se utilizó Validación Walk-Forward con Ventana Expansiva. Este esquema simuló las restricciones de la operativa institucional real: los modelos realizaron predicciones de un paso adelante y fueron re-entrenados periódicamente (cada 50 días operativos) incorporando el nuevo bloque de información disponible. Este enfoque permitió evaluar dinámicamente la capacidad de adaptación de cada algoritmo frente al cambio de régimen de mercado (Concept Drift), permitiendo una comparación justa y secuencial en un entorno de estrés financiero.

4.6 Indicadores Técnicos y Variables de Momentum

El análisis técnico representa una herramienta esencial en la modelación cuantitativa de series financieras, ya que permite identificar patrones de corto plazo y señales recurrentes en los precios de los activos. A diferencia del análisis fundamental (centrado en variables macroeconómicas o contables), el análisis técnico se basa exclusivamente en la información contenida en los precios y volúmenes históricos, bajo la premisa de que “el mercado descuenta toda la información disponible” (Achelis, 2001).

Dentro de las múltiples herramientas técnicas, los indicadores de momentum ocupan un lugar central, pues miden la velocidad y dirección de los movimientos del precio, ofreciendo señales que anticipan cambios de tendencia o sobreextensiones de mercado. Estos indicadores constituyen variables derivadas del precio que pueden incorporarse como *features* en modelos predictivos.

- ❖ **Moving Average Convergence Divergence (MACD):** Es un indicador de seguimiento de tendencia desarrollado por Gerald Appel (1979). Mide la relación entre dos medias móviles exponenciales (EMA) del precio y se utiliza para identificar cambios en la dirección, magnitud y duración de una tendencia.

$$MACD_t = EMA_{12}(P_t) - EMA_{26}(P_t)$$

$EMA_{12}(P_t)$ es la media exponencial de 12 períodos

$EMA_{26}(P_t)$ es la media exponencial de 26 períodos

A partir de esta diferencia, se construye una segunda línea denominada “línea de señal”, que es una EMA de 9 periodos del propio MACD.

$$Signal_t = EMA_9(MACD_t)$$

El histograma del MACD se obtiene como la diferencia entre el MACD y su línea de señal:

$$Histogram_t = MACD_t - Signal_t$$

En contextos de alta volatilidad, como los mercados emergentes, el MACD ayuda a suavizar el “ruido” del precio y detectar *Regime Shifts* (por ejemplo, periodos de recuperación o corrección). En modelos predictivos, los valores del MACD y su histograma suelen incluirse como *features* para representar el momentum del mercado.

❖ Relative Strength Index (RSI)

El RSI, propuesto por J. Welles Wilder (1978), es un oscilador de momento que mide la velocidad y el cambio de los movimientos de precio. Su propósito es identificar condiciones de sobrecompra (overbought) o sobreventa (oversold), anticipando posibles reversiones de tendencia.

Se calcula mediante la fórmula:

$$RSI_t = 100 - \frac{100}{1 + RS_t}$$

$$RS_t = \frac{\text{Media de ganancias en } n \text{ periodos}}{\text{Media de pérdidas en } n \text{ periodos}}$$

En índices bursátiles emergentes, donde los periodos de euforia y corrección son frecuentes, el RSI es un indicador clave para medir el exceso de *momentum*. Además, en modelos de *machine learning*, se incluye como predictor para capturar fases del ciclo de mercado: cuando RSI es alto, suelen aumentar las probabilidades de un retroceso; cuando es bajo, de recuperación.

4.7 Determinantes Macroeconómicos del Mercado Bursátil Chileno

La identificación de las variables explicativas que inciden en la volatilidad y tendencia del IPSA constituye, en esencia, un análisis de los factores fundamentales que rigen la macroeconomía chilena. Dado que Chile se caracteriza estructuralmente como una economía pequeña y abierta al comercio global, su mercado de capitales presenta una alta sensibilidad y dependencia hacia *shocks* externos, variaciones en los términos de intercambio y flujos de capital internacional. En este contexto, el índice bursátil local no opera como un sistema aislado, sino que actúa como un barómetro anticipado de la actividad económica y las expectativas financieras del país.

4.7.1 El Precio del Cobre

La condición de Chile como principal productor mundial hace que el peso chileno opere como una "Commodity Currency" (Chen & Rogoff, 2003), transmitiendo la volatilidad del cobre al IPSA mediante tres canales: fiscal (mayores ingresos que impulsan expectativas del PIB), cambiario (apreciación del peso que favorece la valorización en dólares) y de expectativas, donde el metal actúa como proxy de la demanda de China (Troncoso, 2025). Metodológicamente, se utilizaron los futuros del cobre en COMEX en lugar del precio *spot* de la Bolsa de Metales de Londres (LME). Esta decisión técnica permite la sincronización temporal intradía, ya que COMEX opera simultáneamente con la Bolsa de Santiago, evitando el sesgo de información rezagada que generaría el horario de cierre europeo.

4.7.2 Tipo de Cambio (USD/CLP)

El tipo de cambio actúa como mecanismo de absorción de *shocks* e impacta el mercado local (Abdalla & Murinde, 1997) a través del efecto valoración (reduciendo el retorno en dólares para extranjeros; Calvo, 1996), el encarecimiento de la deuda corporativa en moneda extranjera (Demirkiliç, 2021) y como reflejo del ciclo de liquidez global (Miranda-Agrippino & Rey, 2022). Para el entrenamiento de los modelos predictivos, se utilizó la serie de precios de cierre del mercado *spot* en lugar del "Dólar Observado" del Banco Central. Esto es crucial para evitar sesgos de anticipación, ya que el Dólar Observado es un promedio de transacciones del día anterior ($t-1$), mientras que el precio *spot* captura la volatilidad intradiaria alineada al cierre del IPSA.

4.7.3 Influencia de Mercados Internacionales (S&P 500-FXI)

La integración de los mercados financieros globales implica que los retornos de una bolsa emergente como la chilena no dependen exclusivamente de factores idiosincrásicos locales, sino que presentan una alta sensibilidad a los movimientos de las plazas bursátiles desarrolladas y a los ciclos de liquidez internacional. Bajo la hipótesis de integración financiera (Forbes & Rigobon, 2002), los *shocks* de volatilidad en los centros financieros globales se transmiten hacia mercados periféricos a través de mecanismos de contagio y rebalanceo de portafolios.

- ❖ **S&P500 (Tendencia de Mercado):** Este índice actúa como la referencia mundial del costo de capital y el sentimiento de mercado (*Market Sentiment*). Históricamente, el IPSA mantiene una correlación positiva con el S&P 500, operando este último como una medida del riesgo sistemático global (Beta). No obstante, esta relación no es estática.

Evidencia reciente destaca un fenómeno de "desacople" temporal o *catch-up*, donde el IPSA ha mostrado resiliencia frente a correcciones en Wall Street. Este comportamiento se atribuye a un diferencial de valoraciones: mientras el mercado estadounidense ajusta múltiples exigentes ante entornos de tasas altas, la bolsa local atrae flujos por sus valoraciones castigadas, actuando como un activo de refugio relativo dentro de los mercados emergentes.

- ❖ **Índice VIX (Aversión al Riesgo Global):** Como complemento indispensable al análisis de tendencia, se incorpora el CBOE Volatility Index (VIX). Este indicador mide la volatilidad implícita de las opciones del S&P 500 y es reconocido académicamente como el *proxy* del "miedo inversionista". Para mercados emergentes, el VIX es una variable crítica de flujo de capitales: empíricamente, alzas bruscas (*spikes*) en el VIX detonan ventas masivas en activos de riesgo independientemente de los fundamentos locales, activando el mecanismo de "vuelo a la calidad" (*Flight-to-Quality*). Su inclusión permite al modelo distinguir entre una caída del IPSA por razones económicas y una caída por pánico global.
- ❖ **MSCI China / ETF FXI (El Motor de Mercados Emergentes):** Más allá del precio del cobre, la economía chilena presenta una exposición directa a la salud financiera de China. La inclusión de un indicador bursátil chino permite capturar las expectativas de crecimiento del gigante asiático antes de que estas se reflejen completamente en los precios de las materias primas. Tal como indican los reportes de estrategia de Renta4 y Fintual (citados en Troncoso, 2025), los paquetes de estímulo fiscal y monetario implementados por China para sostener su crecimiento del 5% generan un efecto derrame (*spillover effect*) positivo sobre los activos chilenos, diferenciándolos de otros mercados emergentes menos vinculados al ciclo asiático.

Justificación Metodológica y Sincronización Horaria: Para la operacionalización de estas variables en los modelos de *Machine Learning*, se ha optado por utilizar instrumentos que cotizan en la zona horaria occidental (Nueva York) para mejorar la sincronización de datos intradía:

1. Para el mercado estadounidense, se utilizará el índice S&P 500 o sus futuros E-mini y el índice VIX.
2. Para el mercado chino, no se utilizará el índice Shanghai Composite (que cierra mientras Chile duerme), sino el ETF iShares China Large-Cap (FXI) que cotiza en el NYSE.

El uso del FXI es una decisión técnica crítica: al cotizar en horario americano, este instrumento incorpora en tiempo real la reacción de los inversionistas globales a las noticias nocturnas de China y a los eventos del día en EE. UU., entregando al modelo (LSTM) una variable explicativa que está temporalmente alineada con el cierre del IPSA, evitando así el problema de información desactualizada que generaría el uso de índices asiáticos con desfase horario.

4.7.4 Tasas de Interés, Riesgo Soberano y ciclo Económico

La tasa de interés y sus derivados constituyen la piedra angular de la valoración de activos financieros, actuando simultáneamente como el denominador en los modelos de flujo de caja descontado (DCF) y como indicadores adelantados del ciclo económico. Según la evidencia de Bernanke y Kuttner (2005), los choques en las tasas no solo alteran el costo de capital, sino que modifican las primas de riesgo exigidas por los inversionistas para mantener activos de renta variable.

Para capturar la estructura completa del costo de oportunidad y el riesgo macroeconómico que afecta al IPSA, se incorporan cuatro dimensiones complementarias:

- ❖ **Política Monetaria Local (TPM):** Define el costo de fondeo doméstico y actúa como la tasa libre de riesgo base. De acuerdo con el *Informe de Política Monetaria (IPoM)* de diciembre de 2025 del Banco Central de Chile, la convergencia inflacionaria ha consolidado un ciclo de normalización monetaria. Esta variable actúa como un determinante de "régimen base": niveles altos de TPM comprimen las valorizaciones al elevar la tasa de descuento de los flujos futuros y encarecer el servicio de la deuda, mientras que los recortes actúan como catalizadores de liquidez y expansión de márgenes para sectores sensibles como la banca y el retail.
- ❖ **Costo de Oportunidad Global (US Treasury Yield):** Dada la integración financiera de Chile, la tasa del Bono del Tesoro de los Estados Unidos a 10 años (*US 10-Year Treasury Yield*) opera como la tasa libre de riesgo de referencia mundial (*Benchmark*). Según Neumeyer y Perri (2005), un alza en esta tasa incrementa el atractivo de la renta fija segura en dólares frente a la renta variable emergente, activando mecanismos de arbitraje que incentivan la salida de capitales (*Flight-to-Quality*) desde bolsas periféricas como Santiago hacia bonos norteamericanos.

- ❖ **EMBI Chile (Prima por Riesgo Soberano):** Para aislar el riesgo idiosincrático de Chile (ruido político, fiscal o social) del riesgo de mercado global, se incorpora el *Emerging Markets Bond Index* (EMBI Chile) calculado por J.P. Morgan. Esta variable mide el diferencial (*spread*) entre el rendimiento de los bonos soberanos chilenos y los del Tesoro estadounidense. Su inclusión es crítica para el modelo: permite identificar caídas del IPSA que no responden a factores externos, sino a un deterioro en la percepción de la solvencia o estabilidad institucional local.
- ❖ **Spread de Tasas EE. UU. (10Y - 3M):** Mientras que el rendimiento del bono a 10 años mide el nivel absoluto del costo de oportunidad, el diferencial o *spread* entre las tasas larga (10 años) y corta (3 meses) captura la pendiente de la curva de rendimientos (*Yield Curve Slope*). Esta variable actúa como el *proxy* más robusto del ciclo económico global. La literatura clásica (Estrella & Mishkin, 1998) documenta que una inversión de la curva (*spread* negativo) ha precedido a la mayoría de las recesiones en EE. UU. desde 1950. Para el modelo predictivo, esta variable funciona como un "sistema de alerta temprana": un aplanamiento o inversión de la curva indica al algoritmo que, independientemente del nivel de tasas actual, las expectativas de crecimiento futuro y demanda de materias primas se están deteriorando.

Justificación Metodológica y Selección de Variables: Dada la heterogeneidad de los enfoques predictivos implementados (Econométricos, *Machine Learning* e Híbridos), la selección de variables exógenas (X) se ha diseñado para satisfacer los requerimientos de información de cada arquitectura. Mientras que los modelos lineales (ARIMAX) requieren regresores estructurales, los algoritmos no lineales (Random Forest, LSTM) demandan características con alta variabilidad informativa.

1. **Variables de Régimen y Estructura (TPM):** Aunque su frecuencia de actualización es discreta, la Tasa de Política Monetaria es fundamental para el segmentado de escenarios. Para modelos de árboles de decisión (Random Forest y XGBoost), el nivel de la TPM actúa como un nodo de decisión crítico que permite diferenciar periodos de expansión o contracción monetaria. Simultáneamente, en modelos econométricos (ARIMAX), funciona como una variable exógena determinante para ajustar la tendencia central de la serie ante cambios de política.
2. **Variables de Alta Frecuencia y Expectativas (TNX, EMBI, Spread):** Al cotizar diariamente, estas series proveen la variabilidad continua indispensable para que arquitecturas sensibles como las redes neuronales (LSTM) y los modelos híbridos

logren detectar patrones no lineales y cambios de tendencia con una mejor resolución temporal. Esta granularidad permite operacionalizar dos dimensiones críticas: por un lado, el Spread (10Y-3M) dota al sistema de capacidad anticipatoria sobre los puntos de giro del ciclo económico (expansión/recesión), y por otro, la inclusión del EMBI, Chile actúa como un filtro discriminante que aísla los *shocks* de incertidumbre idiosincrática del pánico global (VIX), reduciendo el riesgo de confusión en el algoritmo entre correcciones sistémicas externas con deterioros en los fundamentos locales.

5 METODOLOGÍA

Este estudio se enmarca en una simulación de campo/experimentación (Tipo IV), ya que reproduce el comportamiento de los mercados financieros mediante modelos econométricos y de machine learning aplicados sobre bases de datos históricos, con el fin de comparar su capacidad predictiva bajo condiciones controladas. Para el desarrollo se define una metodología estructurada en siete etapas principales, las cuales combinan herramientas econométricas, de aprendizaje automático y de simulación estadística.

5.1 Procedimiento

a) Recolección y preprocesamiento de datos (Yahoo Finance, Investing).

Se recopilan series históricas con foco en el mercado chileno, definiendo al índice IPSA como la variable objetivo. Para capturar el entorno macrofinanciero, se integran referencias internacionales (S&P500, FXI), commodities (Cobre), tasas de rendimiento (Yield 10Y), riesgo país (EMBI) y la Tasa de Política Monetaria (TPM). El preprocesamiento incluye la limpieza exhaustiva de datos, cálculo de retornos logarítmicos y la aplicación de Diferenciación Fraccional (FFD) a las series no estacionarias, técnica que permite estacionarizar las variables sin destruir su memoria de largo plazo. Adicionalmente, se construyen *features* técnicos (MACD, RSI, ATR) e indicadores de volatilidad condicional (EGARCH).

b) Preprocesamiento y Generación de variables

Eliminación de valores atípicos y normalización de datos, cálculo de precios logarítmicos, aplicación de Fractional Differencing (FFD) para mantener memoria de largo plazo y estacionariedad. Se construyen variables de entrada (features) que capturan distintos aspectos del mercado:

- ❖ Volatilidad móvil y correlaciones dinámicas.
- ❖ Indicadores técnicos: MACD, RSI, CCI.
- ❖ Rezagos de retornos ($t-1$, $t-2$, ...) y ventanas móviles de precios y volumen

Para los modelos de ensamble (Random Forest y XGBoost), la arquitectura de entrada consiste en una ventana deslizante de 60 rezagos para cada variable del banco de información. Esta configuración permite que el algoritmo evalúe de forma no lineal la persistencia temporal de las variables exógenas, identificando automáticamente qué retardos específicos poseen mayor poder predictivo.

En contraste, para el modelo econométrico ARIMAX, se optó por una estructura de rezagos de primer orden ($t-1$) para las variables exógenas. Esta decisión técnica permite la causalidad temporal del modelo, haciendo que la predicción se fundamente exclusivamente en información ya cerrada del mercado internacional, lo que mitiga el riesgo de sesgo de anticipación (*look-ahead bias*). Bajo este esquema, la captura de la memoria histórica no recae en la profundidad de las variables externas, sino en el componente autorregresivo (p) de la propia serie.

Para validar la robustez del diseño de variables, se realizó un análisis de correlación de Pearson sobre las series transformadas (ver Anexo A). Los resultados sugieren una notable ortogonalidad entre las variables macroeconómicas, globales y técnicas, confirmando que la diferenciación fraccional mitigó exitosamente las correlaciones espurias originadas por tendencias subyacentes. Si bien se detectó multicolinealidad estructural ($r > 0.90$) de manera exclusiva en el bloque de microestructura de precios (Open, High, Low, Price), se optó por la preservación íntegra de estas variables. Esta decisión técnica se fundamenta en que los algoritmos de ensamblaje y aprendizaje profundo (Random Forest, XGBoost, LSTM) utilizan el diferencial implícito entre estos valores para extraer patrones de volatilidad y rangos intradiarios, gestionando la redundancia mediante sus propios mecanismos de submuestreo de características.

c) Modelado econométrico

Los modelos de la familia EGARCH no se utilizan exclusivamente como generadores de riesgo direccional, sino que cumplen un doble propósito estructural: actúan como variables predictoras de volatilidad condicional (*features*), y dictan la amplitud dinámica de los umbrales

de *Take Profit* y *Stop Loss* en la simulación de la Triple Barrera, ajustando el riesgo a la complejidad del entorno.

- ❖ ARIMA/ARIMAX: Establecido como el modelo referencial lineal, utilizado para la predicción direccional base incorporando bancos de variables exógenas.
- ❖ EGARCH: Modela la volatilidad condicional del mercado, capturando asimetrías y efectos de apalancamiento (*leverage effect*) para la gestión dinámica del riesgo.

d) Modelado Machine Learning

Aplicación de algoritmos de aprendizaje supervisado de estado del arte para la clasificación direccional y captura de patrones no lineales bajo alta dimensionalidad:

- ❖ Random Forest: ensamble de árboles para robustez y reducción de varianza.
- ❖ XGBoost: boosting regularizado de alto rendimiento.
- ❖ LSTM: redes neuronales recurrentes con memoria de largo plazo.
- ❖ BiLSTM: extensión bidireccional para dependencias secuenciales más profundas.

e) Modelado híbrido

- ❖ ARIMA–LSTM : Arquitectura de estabilización secuencial donde el componente ARIMA modela la tendencia lineal autorregresiva base, delegando a la red LSTM el modelado exclusivo de los residuos estocásticos no lineales.
- ❖ LSTM–RF: La red LSTM actúa como un codificador que comprime la ventana temporal en representaciones latentes, las cuales alimentan al clasificador Random Forest, combinando el aprendizaje secuencial con la eficiencia computacional en etapas de re-entrenamiento dinámico.

f) Validación y Evaluación

Para evitar la fuga de información (*data leakage*) inherente a las series de tiempo, la optimización de hiperparámetros se realiza sobre el conjunto de entrenamiento mediante *Purged K-Fold Cross-Validation*, aplicando una purga igual a la ventana de observación y un embargo temporal posterior al test para aislar la correlación serial. Posteriormente, se emplea un esquema *Walk-Forward* con ventana expansiva para la evaluación *Out-of-Sample*, re-entrenando periódicamente los modelos para capturar cambios de régimen (*Concept Drift*).

Las probabilidades emitidas por los modelos alimentan un simulador de ejecución basado en el Método de la Triple Barrera (López de Prado, 2018), el cual evalúa umbrales dinámicos de toma de ganancias (*Take Profit*), límite de pérdidas (*Stop Loss*) ajustados por volatilidad, y un tiempo máximo de retención (*Max Hold*). Para simular realismo institucional, el simulador incorpora un costo de fricción del 0.16% por transacción completa (comisión + *slippage*). El desempeño final se evalúa a través de métricas ajustadas por riesgo: Alpha Neto, Sharpe Ratio, STARR, Maximum Drawdown (MDD) y Win Rate.

g) Discusión y análisis comparativo

El estudio de ablación se estructura mediante la agrupación de variables en "Bancos de Información" (Univariado, Macros, Global, Técnicos, Total). Esto permite aislar y evaluar qué conjunto de *features* maximiza la señal predictiva para cada algoritmo. Finalmente, el análisis comparativo evalúa el comportamiento evolutivo de las distintas arquitecturas (lineales, recurrentes, de ensamble e híbridas) frente a *shocks* estructurales del mercado, priorizando la resiliencia algorítmica y la gestión de varianza sobre la precisión de clasificación aislada.

5.2 Diseño de Bancos de Información (Estudio de Ablación)

Para evaluar el poder predictivo aislado y combinado de las distintas dimensiones del mercado, las variables se agruparon en siete "Bancos de Información".

Tabla 1. Composición de los Bancos de Información

Banco	Variable Exógenas Incluidas	Justificación
Univariado	Ninguna	Línea base. Evalúa la memoria pura de la serie.
Precio_Puro	Open,High,Low	Captura la microestructura intradiaria del activo.
Macros	TPM,EMBI,COBRE,Yield 10Y (EE.UU)	Representa el ciclo económico y riesgo soberano.
Global	S&P 500, VIX, FXI	Sentimiento internacional y flujos de liquidez.
Técnicos	MACD,RSI,ATR,EGARCH	Mide el momentum, sobrecompra/venta y varianza.
Híbrido_Precio_Tec	Open,High,Low,EGARCH,RSI	Combina microestructura con momentum y riesgo.
Total	Todas	Evalúa la capacidad del modelo ante alta dimensionalidad.

Se realizó un análisis de correlación de Pearson sobre las variables transformadas para validar la independencia de los bancos. Los resultados evidenciaron la alta correlación en variables de microestructura (OHLC), los cuales se mantuvieron de forma deliberada para permitir que los algoritmos capturen la volatilidad intradía y la persistencia de tendencia, delegando la gestión de la redundancia a los mecanismos de submuestreo de características de los modelos de ensamble (ver mapa de calor en Anexo A).

6 ANÁLISIS DE RESULTADOS EXPERIMENTALES

6.1 Entorno de Simulación y Condiciones de Mercado

En el presente capítulo se exponen los resultados obtenidos tras el entrenamiento, optimización y evaluación de las distintas arquitecturas. A diferencia de los enfoques tradicionales de predicción financiera que priorizan la minimización del error de regresión (mediante métricas como RMSE o MAPE), esta investigación adopta un paradigma orientado a la gestión del riesgo y la ejecución operativa.

Para procurar la validez institucional de los hallazgos, las probabilidades emitidas por cada modelo no fueron evaluadas en el vacío, sino que alimentaron un simulador de ejecución basado en el Método de la Triple Barrera (López de Prado, 2018), imponiendo adicionalmente una fricción transaccional del 0.16% por cada operación completa (round-trip).

El periodo de evaluación fuera de muestra reviste particular importancia para este análisis, dado que abarca tanto una fase de mercado alcista sostenido como un cambio de régimen a principios del año 2026. Este escenario permite someter a las arquitecturas momentos de mayor volatilidad, evaluando no solo su capacidad para maximizar el retorno durante las expansiones económicas, sino, críticamente, su resiliencia para preservar el capital. A continuación, se detalla el comportamiento de las estrategias.

Establecimiento de la Línea Base (Benchmark)

Para cuantificar la generación de valor de los algoritmos, se definió como *Benchmark* una estrategia pasiva de *Buy & Hold* (Comprar y Mantener) sobre el índice IPSA durante el mismo periodo *Out-of-Sample*. Las métricas de esta estrategia representan el comportamiento natural del mercado y sirven como umbral mínimo de exigencia :

- Retorno Acumulado: 94.91%
- Sharpe Ratio 1.28
- Maximum Drawdown(MDD): -15.94%
- CVaR: -2.07%
- STARR: 0.04

Este portafolio establece el umbral base de evaluación. Dado que las estrategias algorítmicas de ejecución activa incurren en costos de fricción y asumen riesgo direccional, es esperable que puedan registrar *Drawdowns* más profundos que la simple tenencia del índice. Por consiguiente, un modelo podría considerarse mejor que el *Benchmark* si su exceso de retorno (Alpha Neto) logra justificar la toma de ese riesgo adicional, reflejándose en una eficiencia ajustada por riesgo (Sharpe Ratio) mayor al 1.28 del mercado.

6.2 Desempeño del Enfoque Econométrico (ARIMAX)

Para establecer la línea base de la investigación, se evaluó el desempeño del modelo econométrico ARIMAX.

Los resultados de la fase de validación técnica revelaron que la incorporación de variables exógenas altera de manera relevante la capacidad predictiva del modelo lineal. El estudio de ablación evidencia que el banco Global alcanzó la mayor precisión fuera de muestra (Accuracy OOS) con un 61.01%, bajo una especificación de orden (2, 0, 2). En contraste, el banco Univariado base alcanzó una precisión del 58.08% con un orden (2, 0, 1). Este hallazgo preliminar sugería, desde una perspectiva puramente estadística, que el entorno internacional aportaba información linealmente valiosa para anticipar el IPSA.

Sin embargo, al someter estas predicciones al simulador de ejecución bajo el método de la Triple Barrera, la jerarquía de desempeño tuvo una inversión, exponiendo las severas limitaciones del modelo econométrico frente a la fricción institucional. Durante la simulación de trading el banco Univariado emergió como el mejor de la familia ARIMAX, generando un Alpha Neto de 10.64% (Retorno Neto del 105.55% frente al 94.91% del Benchmark) .

Este mejor desempeño del banco Univariado sobre el Global confirma la hipótesis de parsimonia operativa. Dado que el análisis de correlación (Anexo A) descartó la presencia de multicolinealidad severa en el banco Global, el deficiente desempeño del modelo multivariado se atribuye a la sobreparametrización. En una arquitectura lineal, la adición de múltiples variables exógenas —incluso siendo estadísticamente independientes— introduce un exceso de varianza en la estimación de los coeficientes. Esto genera señales ruidosas que derivan en

un *over-trading* destructivo bajo fricción institucional. Este hallazgo evidencia que, para el enfoque econométrico, la simplicidad paramétrica del banco Univariado proporciona una resiliencia operativa frente a la complejidad de los regresores internacionales.

- **Degradación por Fricción (*Over-trading*):** El ARIMAX Univariado registró un total de 421 operaciones, la frecuencia transaccional más alta del trabajo. Con una tasa de acierto del 51.8%, el modelo operó con un margen de éxito marginalmente superior al azar. Esta hiperactividad, combinada con el pago sistemático de comisiones y *slippage*, actuó como un lastre estructural que redujo el capital acumulado.
- **Vulnerabilidad ante el Cambio de Régimen (*Drawdown*):** La principal debilidad del enfoque econométrico quedó plasmada en su gestión de riesgo extremo. El modelo sufrió un *Maximum Drawdown* (MDD) elevado del -46.79%.




Figura 1. Gráfico de Curva de Capital ARIMAX vs Benchmark

Fuente: Elaboración Propia, mediante herramienta Python

Como se observa en la curva de capital, el modelo ARIMAX logró capturar eficientemente la tendencia durante el mercado alcista de baja volatilidad. Sin embargo, al enfrentar el cambio de régimen y la caída abrupta a principios de 2026, la linealidad estructural de su naturaleza autorregresiva le impidió adaptar sus pronósticos. El modelo manifestó un

fuerte sesgo hacia la tendencia histórica previa, emitiendo múltiples señales de compra en un mercado bajista, lo que provocó colisiones reiteradas contra el umbral de *Stop Loss* y resultó en la reducción de casi la mitad del patrimonio máximo alcanzado, exhibiendo un Ratio de Sharpe deficiente de 1.12.

Estos resultados sugieren que, si bien la econometría clásica es capaz de proyectar direccionalidad en entornos estables, carece de la resiliencia no lineal necesaria para proteger el capital institucional frente a shocks estructurales del mercado.

6.3 Evaluación de Arquitecturas de Deep Learning (LSTM y BiLSTM)

El siguiente paso en la progresión metodológica consistió en evaluar la capacidad de las Redes Neuronales Recurrentes (RNN) para modelar dependencias a largo plazo. Se implementaron dos arquitecturas: una red LSTM estándar y su variante bidireccional (BiLSTM), diseñada teóricamente para extraer mayor contexto procesando la serie temporal en ambas direcciones.

Durante el esquema de validación Walk-Forward, ambas arquitecturas neuronales evidenciando una capacidad direccional consistente, superando la barrera del 58% de acierto (*Accuracy*) en la mayoría de las configuraciones de datos. El modelo BiLSTM mostró una leve ventaja nominal sobre el LSTM clásico en la identificación de tendencias aisladas. Sin embargo, de manera análoga a lo observado con el modelo econométrico, esta aparente ventaja en la clasificación de patrones no se tradujo en supervivencia financiera bajo condiciones operativas reales.

Al procesar las probabilidades a través del simulador de la Triple Barrera, se reveló un cambio estructural en el comportamiento de las redes. Ambos algoritmos lograron su máxima rentabilidad financiera (*Alpha Neto*) abandonando los bancos con los que obtuvieron mayor *Accuracy* y convergiendo hacia el banco Global. La red LSTM generó un *Alpha Neto* de 28.91% (retorno del 122.47%), mientras que el BiLSTM mostró una mayor capacidad extractiva alcanzando un *Alpha Neto* de 39.44% (retorno del 132.99%).

El hecho de que ambas arquitecturas recurrieran a variables internacionales (S&P 500, VIX, FXI) para maximizar su desempeño sugiere que, frente a la complejidad del mercado chileno, el precio fue insuficiente. Las redes necesitaron el contexto de la volatilidad y el sentimiento global para lograr filtrar operaciones ruidosas. Ambos modelos superaron al

Benchmark (que obtuvo un retorno neto de 93.56%), registrando Ratios de Sharpe competitivos de 1.37 y 1.41.




Figura 2. Gráfico de Curva de Capital BiLSTM vs LSTM vs Benchmark

Fuente: Elaboración Propia, mediante herramienta Python.

Como se evidencia en la curva de capital, ambas redes neuronales mostraron un desempeño sobresaliente durante las fases de fuerte tracción alcista, logrando un desacople masivo respecto al índice debido a su capacidad para modelar dependencias complejas.

No obstante, el perfil de riesgo expone una limitación en la gestión de turbulencias intermedias. Si bien los modelos sufren una contracción en la crisis de 2026, el gráfico revela que su debilidad estructural (*Maximum Drawdown*) se manifestó antes, durante las abruptas correcciones de finales de 2023 y mediados de 2024. En estos periodos, mientras el mercado (línea negra punteada) asimilaba retrocesos moderados y un MDD histórico manejable del -15.94%, el LSTM y el BiLSTM multiplicaron el riesgo, registrando caídas sustanciales del -31.84% y -33.62%, respectivamente.

Este fenómeno de desplome prematuro se atribuye a la "inercia de memoria" (*Memory Inertia*) inherente a sus celdas de estado:

- Debido a que la memoria a largo plazo de las redes estaba fuertemente ponderada por los impulsos alcistas previos, los algoritmos no fueron capaces de

dejar de lado la tendencia con suficiente rapidez ante las correcciones de mitad de ciclo.

- Al enfrentarse a estos retrocesos estructurales (2023 y 2024), los modelos continuaron emitiendo señales de compra (*Catching a falling knife*), colisionando reiteradamente contra los límites de *Stop Loss* y con una severa reducción de capital antes de lograr recuperarse.

Los resultados evidencian que la visión retrospectiva profunda, e incluso la lectura bidireccional del BiLSTM, resultan contraproducentes ante shocks inéditos del mercado. En finanzas cuantitativas, la agilidad para descartar información obsoleta y cortar la exposición al riesgo resulta ser más crítica que la capacidad de retener patrones prolongados.

6.4 Algoritmos de Ensamble y Reducción de Varianza (Random Forest y XGBoost)

Para superar las limitaciones de los modelos lineales y las redes recurrentes, se evaluó el desempeño de los algoritmos de ensamble basados en árboles de decisión. Se contrastaron dos arquitecturas que abordan el error predictivo desde perspectivas matemáticas opuestas: Random Forest, enfocado en la reducción de varianza mediante *Bagging* (entrenamiento paralelo independiente), y XGBoost, enfocado en la reducción de sesgo mediante *Boosting* (optimización secuencial de errores).

En la etapa de validación de hiperparámetros (Estudio de Ablación), el enfoque de *Boosting* evidenció el mejor desempeño direccional de la muestra. El XGBoost alcanzó un *Accuracy* predictivo máximo de 60.42% utilizando el banco Híbrido_Precio_Tec, superando nominalmente al Random Forest, cuyo mejor registro fue un 56.29% con el banco Técnicos.

Ambos algoritmos, al ser sometidos a la simulación financiera, encontraron su configuración más rentable operando con el banco Global (que incluye el S&P 500, FXI y VIX). En este banco específico, el *Accuracy* base del XGBoost (56.85%) también era superior al del Random Forest (53.73%). Bajo la métrica tradicional de la ciencia de datos, el XGBoost debió ser el de mayor retorno. Sin embargo, la simulación con fricción institucional expuso la trampa del sobreajuste direccional.

Al transformar las probabilidades en decisiones de *trading* a través de la Triple Barrera, el RF alteró la jerarquía de desempeño observada en la fase de entrenamiento consolidándose como el modelo con el mejor desempeño de la investigación. Generó un Alpha Neto de

112.29% (retorno acumulado del 205.85%), en contraste con el Alpha de 44.28% obtenido por el XGBoost.

Esta significativa divergencia entre la precisión direccional convencional y rentabilidad financiera se explica al analizar las métricas operativas de ambos modelos:

- **Eficiencia Transaccional:** Aunque ambos modelos realizaron una cantidad de operaciones casi idéntica (274 para RF y 277 para XGB), el *Win Rate* del Random Forest en operaciones ascendió a 56.6%, mientras que el del XGBoost cayó a 54.5%. Esto evidencia que el Random Forest generó señales de mayor convicción y mejor calibradas para los umbrales dinámicos de volatilidad, minimizando los *Stop Loss* y mitigando el impacto del 0.16% de fricción.
- **Gestión de Riesgo Asimétrico:** El Random Forest alcanzó un Ratio de Sharpe de 2.01, posicionándose como la estrategia que muestra mejor desempeño en el estudio, frente al 1.57 del XGBoost.




Figura 3. Gráfico de Curva de Capital RF vs XGB vs Benchmark

Fuente: Elaboración Propia, mediante herramienta Python.

La curva de capital ilustra la divergencia estructural entre ambas metodologías. Durante la primera mitad del periodo (2023), el XGBoost mostró un comportamiento errático, llegando a superar inicialmente al Random Forest. Sin embargo, la fase de contracción que definió el

rendimiento relativo de los modelos no ocurrió en 2026, sino durante las correcciones de fines de 2024.

En este periodo de turbulencia intermedia, el XGBoost evidenció su gran vulnerabilidad: sufrió una caída que lo llevó a registrar su *Maximum Drawdown* (MDD) de -27.61%. Esta degradación de capital mermó su momento alcista (*momentum*), dejándolo estancado y con un crecimiento degradado durante toda la fase expansiva posterior de 2025.

En estricto contraste, la arquitectura de *Bagging* del Random Forest evidenció una resiliencia de recuperación mayor. Si bien el modelo también absorbió el golpe de 2024 (registrando un MDD acotado al -25.08%), la partición de varianza de sus múltiples árboles le permitió aislar el ruido, ejecutar una recuperación en forma de 'V' y capitalizar explosivamente el ciclo alcista de 2025.

Finalmente, al producirse el cambio de régimen a inicios de 2026, ocurre un fenómeno revelador: el XGBoost efectivamente logra "apagarse" y aplanar su curva para evitar la caída, mientras que el Random Forest absorbe una corrección parcial. No obstante, gracias a la inmensa brecha de capital compuesto que el Random Forest construyó durante su recuperación, finaliza la simulación generando la mayor rentabilidad ajustada por riesgo. Esto sugiere que la ventaja financiera no solo radica en evadir el periodo de alta volatilidad, sino en la agilidad estructural para recuperarse de los *drawdowns* intermedios.

6.5 Evaluación de Arquitecturas Híbridas (ARIMA-LSTM y LSTM-RF)

La última fase experimental de la investigación se centró en evaluar si la combinación de distintas familias algorítmicas podía mitigar las debilidades individuales frente al cambio de régimen de 2026. Se contrastaron dos paradigmas de hibridación: uno secuencial (ARIMA-LSTM) que busca separar la señal lineal del ruido, y uno de extracción de características (LSTM-RF) que intenta combinar la memoria profunda con la clasificación mediante árboles.

La integración del modelo econométrico tradicional con la red neuronal recurrente produjo uno de los resultados más reveladores. Durante la validación técnica (*Accuracy*), el modelo alcanzó su mayor precisión direccional (61.23%) utilizando el banco Global. Sin embargo, al trasladar las predicciones al simulador de la Triple Barrera, el modelo encontró su máxima rentabilidad operando de forma estrictamente autónoma con el banco Univariado.

El ARIMA-LSTM generó un Alpha de 101.29% (retorno acumulado del 196.20%), posicionándose como la segunda estrategia más rentable de la investigación. Este fenómeno evidencia una complementariedad operativa significativa entre ambas arquitecturas:

- **Separación de Tareas:** El componente ARIMA absorbió la tendencia base (la parte lineal), permitiendo que las celdas de memoria del LSTM se concentran exclusivamente en aprender la estructura no lineal de los residuos.
- **Extracción Pura de Señal:** Al lograr un desempeño elevado utilizando únicamente la historia del propio índice, la arquitectura evidenció una notable autosuficiencia. Esto no disminuye la utilidad de las variables exógenas sugeridas por otros modelos, sino que la sinergia del modelo logró analizar la variable precio con una eficiencia que el LSTM puro no llegó.
- **Gestión de Riesgo:** Aunque registró un volumen transaccional alto (361 operaciones), mantuvo un Ratio de Sharpe robusto de 1.74 y contuvo el *Maximum Drawdown* a un -29.05%, la severa contracción de capital que experimentaron las redes neuronales puras durante la crisis.

En contraposición a la sinergia observada en el primer híbrido, la arquitectura LSTM-RF evidenció que mezclar dos modelos complejos puede resultar contraproducente. En esta configuración, el LSTM actuó como un extractor de características que comprimía los últimos 60 días del mercado para alimentar al Random Forest clasificador.

A nivel de *accuracy*, se osciló entre el 56.74% y el 59.42%. En la simulación financiera, su configuración más rentable se dio utilizando el banco Macros (TPM, EMBI, Cobre, Yield 10Y), con el cual generó un Alpha Neto de 45.47% (retorno acumulado de 139.03%), bastante por debajo del 112% generado por el Random Forest en solitario.

Esta degradación del desempeño radica en un conflicto de arquitecturas (*Noise Contamination*):

- **Herencia de Defectos:** En lugar de ayudar al Random Forest, la capa extractora del LSTM le transmitió su principal vulnerabilidad: la inercia de memoria.
- **Fallas en el Corte de Riesgo:** El híbrido exhibió una respuesta tardía ante correcciones prolongadas, comportamiento que resulta consistente con la

naturaleza de la red neuronal. Como se observa en la gráfica, esto se tradujo en un *Maximum Drawdown* del -31.08% materializado a lo largo del segundo semestre de 2023 y principios de 2024. Mientras el Random Forest puro lograba cortes rápidos de pérdidas (-25.08%), al depender de los datos filtrados secuencialmente por el LSTM, el modelo híbrido LSTM-RF promedió a la baja y con un desgaste lento de capital.




Figura 4. Gráfico de Curva de Capital ARIMA-LSTM vs LSTM-RF vs Benchmark

Fuente: Elaboración Propia, mediante herramienta Python

La curva de capital ilustra claramente esta brecha estructural. El ARIMA-LSTM exhibe una trayectoria ascendente. Si bien la estrategia experimenta contracciones severas, evidenciando su *Maximum Drawdown* a mediados de 2024 y absorbiendo parte del impacto sistémico a inicios de 2026, su capacidad para capturar dinámicas no lineales en los residuos le permite ejecutar recuperaciones en forma de 'V', retomando su senda de maximización de retornos.

Por el contrario, el LSTM-RF muestra un comportamiento constante tras su profunda contracción a finales de 2023. Resulta revelador que, aunque el modelo logra estabilizarse y evadir una caída abrupta en el 2026. Su limitación para capitalizar la fase expansiva de 2025 evidencia una marcada desventaja operativa frente a las arquitecturas individuales.

En conclusión, la evaluación de arquitecturas híbridas sugiere que la complejidad adicional solo se justifica financieramente cuando los algoritmos abordan espectros ortogonales de la serie de tiempo (Lineal vs No-Lineal). Cuando se encadenan modelos de la misma naturaleza (No-Lineal + No-Lineal), el riesgo de sobreajuste y la transmisión de inercia superan los beneficios predictivos teóricos, resultando en curvas de capital subóptimas y asumiendo riesgos mayores frente a la ejecución de modelos más simples.

6.6 Comparativa Final y Discusión de Resultados

Para sintetizar los hallazgos de esta investigación, se estructuró una comparativa transversal que evalúa el desempeño de todas las arquitecturas sometidas a las mismas condiciones: simulación *Walk-Forward*, ejecución mediante el Método de la Triple Barrera y un costo de transacción.

La Tabla 2 resume el rendimiento de los modelos, ordenados de mayor a menor rentabilidad financiera (Alpha Neto). Se incluye, además, la precisión direccional (*Accuracy*) máxima alcanzada por cada algoritmo durante la fase de optimización, con el objetivo de contrastar la teoría estadística con la viabilidad operativa.

Tabla 2. Comparación de Modelos con Métricas de Desempeño y Gestión del Riesgo

	Comparación de Modelos						
Métricas	ARIMAX	LSTM	BiLSTM	RF	XGB	ARIMA-LSTM	LSTM-RF
Max Accuracy	61.01%	59.64%	60.76%	56.3%	60.42%	61.23%	59.42%
Variables ¹	Univariado	Global	Global	Global	Global	Univariado	Macros
Alpha (Neto) ²	10.64%	28.91%	39.44%	112.29%	44.28%	101.29%	45.47%
Win (Rate)	51.8%	53.9%	53.8%	56.6%	54.5%	55.7%	56.2%
Trades	421	310	333	274	277	361	258
Sharpe Ratio	1.12	1.37	1.41	2.01	1.57	1.74	1.65
CVaR (95%)	-2.54%	-2.71%	-2.6%	-2.58%	-2.61%	-2.59%	-2.73%
STARR	0.07	0.1	0.1	0.16	0.13	0.12	0.13
MDD	-46.79%	-31.84%	-33.62%	-25.08%	-27.71%	-29.05%	-31.08%

¹ Se eligió el banco de variables respecto al mejor alpha obtenido

² Diferencia entre el retorno neto del modelo y el retorno del mercado (B&H) del 94.91%

El análisis de la tabla comparativa permite extraer tres conclusiones estructurales sobre la aplicación del aprendizaje automático en el mercado bursátil chileno:

6.6.1 La Confiabilidad del Accuracy

El resultado más contraintuitivo de la investigación es la baja relación entre la precisión direccional aislada (*Accuracy*) y la rentabilidad financiera (*Alpha*). El modelo de mejor desempeño, el Random Forest, registró el *Accuracy* más bajo (56.29%). En contraparte, los modelos que superaron la barrera del 60% de precisión (ARIMA_LSTM, XGBoost, ARIMAX y BiLSTM) exhibieron resultados financieros dispares. Esto sugiere que en finanzas cuantitativas, la capacidad de un modelo para predecir un día alcista irrelevante (ruido) se pondera de igual manera en las métricas direccionales que predecir el inicio de una caída sistémica, pero financieramente su valor es asimétrico. El Random Forest triunfó porque su ensamble en paralelo ignoró las micro-fluctuaciones ruidosas y concentró sus aciertos direccionales en los movimientos de mayor magnitud (reflejado en su Sharpe Ratio de 2.01).

6.6.2 La Dependencia del Contexto Internacional (El Dominio del Banco Global)

Resulta notable que cuatro de los cinco algoritmos de *Machine Learning* puros (RF, XGBoost, LSTM, BiLSTM) alcanzaran su máximo desempeño utilizando el banco Global. Esto provee evidencia de que el mercado chileno opera con un alto grado de integración financiera. Los algoritmos no lineales identificaron que, frente a un cambio de régimen, la historia del precio local (*Univariado*) carece de la información necesaria para activar los protocolos de evasión de riesgo. El VIX y los mercados internacionales actuaron como los sensores tempranos que permitieron a los modelos anticipar la volatilidad extrema.

6.6.3 Jerarquía de Arquitecturas frente a Shocks Estructurales

Las severas caídas del mercado (las correcciones abruptas de 2023-2024 y del 2026) funcionaron como el filtro definitivo para evaluar la resiliencia arquitectónica:

- **La Limitación de la Inercia:** La econometría clásica (ARIMAX) y el *Deep Learning* secuencial (LSTM, BiLSTM) mostraron peor desempeño en su gestión de riesgo (Drawdowns superiores al 31%). Su naturaleza matemática hizo que se ponderase excesivamente la tendencia histórica alcista, generando operaciones negativas (*Catching a falling knife*) durante los retrocesos del ciclo.

- **Vulnerabilidad por Sobre-Hibridación:** El modelo LSTM-RF sugiere que apilar arquitecturas complejas puede resultar en la transmisión de vulnerabilidades ("propagación de ruido"), degradando el desempeño del clasificador final.
- **La Sinergia y el Corte Rápido:** Los modelos de mejor desempeño fueron aquellos capaces de aislar el ruido. El ARIMA-LSTM (101% Alpha) logró extraer la señal oculta en los residuos del precio local separando las tareas lineales de las estocásticas. Finalmente, el Random Forest (112% Alpha) sugiere que, en entornos financieros ruidosos y con fricción institucional, un modelo sin memoria secuencial, pero con una alta capacidad de partición de varianza, reaccionando más rápido ante el peligro, protegiendo el capital y maximizando la eficiencia de cada operación.

7 CONCLUSIONES

La presente investigación se desarrolló con el objetivo general de evaluar el desempeño de modelos econométricos, algoritmos de *Machine Learning* y arquitecturas híbridas para el pronóstico direccional y la gestión operativa de riesgo en el mercado chileno (IPSA). A partir de la metodología implementada y los resultados se concluye que los objetivos planteados fueron cumplidos a cabalidad, derivando en los siguientes hallazgos estructurales:

1. Cumplimiento Metodológico y el Paradigma de Evaluación: Se logró estructurar y validar un *pipeline* algorítmico avanzado que mejoraba las limitaciones de la literatura tradicional. La implementación de Diferenciación Fraccionaria (FFD) junto con el protocolo de validación *Purged K-Fold con Embargo* implementó un modelado sin fuga *Data Leakage*. La conclusión metodológica más crítica del estudio es la invalidación de la precisión estática (*Accuracy*) como métrica de éxito financiero. Se evidencia que optimizar un modelo para acertar la mayor cantidad de días no garantiza la rentabilidad; la viabilidad de un algoritmo en mercados ruidosos depende de su capacidad asimétrica para gestionar el riesgo de cola, lo cual exige el uso de simuladores de ejecución (como la Triple Barrera) y métricas de financieras (Alpha, Sharpe, MDD).

2. La Arquitectura Óptima para el Mercado Chileno: En respuesta a la comparativa de modelos, se concluye que la resiliencia estructural domina sobre la complejidad matemática secuencial:

- **El fracaso de la inercia:** Las arquitecturas de memoria profunda (LSTM y BiLSTM) y los modelos lineales (ARIMAX) resultaron ineficientes para gestionar las correcciones abruptas (tanto los *drawdowns* intermedios de 2024 como el periodo de alta volatilidad del 2026).
- **El éxito del ensamble y la ortogonalidad:** El modelo Random Forest se consolidó como la arquitectura individual óptima gracias a la reducción de varianza (*Bagging*), lo que le permitió aislar el ruido, ejecutar recuperaciones compuestas y realizar cortes rápidos de pérdidas. Por su parte, el híbrido ARIMA-LSTM sugiere que la complejidad es útil únicamente cuando se separan funcionalmente las tareas (tendencia lineal vs. residuos).

3. El Rol Crítico del Estimador de Volatilidad (EGARCH): Se evidenció que la emisión de señales direccionales (basadas en el *Accuracy* del modelo) es insuficiente para generar rentabilidad financiera. Los modelos requieren obligatoriamente de una capa de traducción de riesgo, rol que cumplió el estimador de volatilidad condicional EGARCH integrado a la Triple Barrera. Mientras que el algoritmo de *Machine Learning* decidía "hacia dónde" ir, el EGARCH determinaba "cuánto espacio" darle a la operación antes de cortar pérdidas (*Stop Loss*) o tomar ganancias (*Take Profit*).

4. La Dependencia Estructural de Factores Globales El estudio por bancos de variables permitió cumplir el objetivo de aislar el impacto de la información exógena. Se concluye que el mercado bursátil chileno opera bajo un alto grado de integración financiera.

5. Limitaciones y Líneas de Trabajo Futuro Si bien el marco desarrollado resulta altamente competitivo, se identifican oportunidades de expansión para futuras investigaciones:

- **Resolución Temporal:** Escalar el modelo de datos diarios a frecuencias intradiarias (*ticks* o minutos) para optimizar la precisión en la ejecución de los umbrales de *Stop Loss* y *Take Profit*.
- **Estrategias Bidireccionales:** Habilitar un entorno simulado que permita ventas en corto (*Short-Selling*), otorgando a los algoritmos la capacidad de generar Alpha positivo en ciclos de contracción severa.
- **Datos Alternativos:** Integrar Procesamiento de Lenguaje Natural (NLP) sobre noticias y reportes de política monetaria en tiempo real, añadiendo variables de sentimiento macroeconómico explícito a los tensores de entrada.

8 BIBLIOGRAFÍA

1. Abdalla, I. S., & Murinde, V. (1997). Exchange rate and stock price interactions in emerging financial markets: evidence on India, Korea, Pakistan and the Philippines. *Applied Financial Economics*, 7(1), 25-35.<https://doi.org/10.1080/096031097333826>
2. Achelis, S. B. (2001). *Technical Analysis from A to Z* (2nd ed.). McGraw-Hill.
<https://healholistic.wordpress.com/wp-content/uploads/2013/08/achelis-steven-technical-analysis-from-a-to-z.pdf>
3. Andriano, N., & Pribadi, F. S. (2025). Hybrid deep learning models using LSTM with Random Forest for radio frequency-based human activity recognition in line-of-sight and non-line-of-sight environments. *Jurnal Rekayasa ElektriKa*, 21(2). <https://doi.org/10.17529/jre.v21i2.44828>
4. Bailey, D. H., & López de Prado, M. (2014). The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94-107.https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2460551
5. Bernanke, B. S., & Kuttner, K. N. (2005). What explains the stock market's reaction to Federal Reserve policy? *The Journal of Finance*, 60(3), 1221–1257.
<https://doi.org/10.1111/j.1540-6261.2005.00760.x>
6. Box, G. E. P., & Jenkins, G. M. (1976). *Time Series Analysis: Forecasting and Control* (Revised ed.). San Francisco, CA: Holden-Day.
<https://download.e-bookshelf.de/download/0003/8810/69/L-G-0003881069-0007953902.pdf>
7. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.<https://doi.org/10.1023/A:1010933404324>
8. Calvo, G. A., Leiderman, L., & Reinhart, C. M. (1996). Inflows of Capital to Developing Countries in the 1990s. *Journal of Economic Perspectives*, 10(2), 123-139.<https://www.aeaweb.org/articles?id=10.1257/jep.10.2.123>
9. Chen, T., & Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).<https://dl.acm.org/doi/10.1145/2939672.2939785>
10. Chen, Y.-C., & Rogoff, K. (2003). Commodity currencies. *Journal of International*

- Economics*, 60(1), 133–160. [https://doi.org/10.1016/S0022-1996\(02\)00072-7](https://doi.org/10.1016/S0022-1996(02)00072-7)
11. Corbo, V., & Schmidt-Hebbel, K. (2013). La crisis internacional y América Latina. *Revista Monetaria*. Centro de Estudios Monetarios Latinoamericanos (CEMLA). https://www.cemla.org/PDF/monetaria/PUB_MON_XXXV-01-02.pdf
12. Demirkılıç, S. (2021). Balance sheet effects of foreign currency debt and real exchange rate on corporate investment: evidence from Turkey. *Emerging Markets Review*, 47, 100796. <https://doi.org/10.1016/j.ememar.2021.100796>
13. Domenteanu, A., Diaconu, P., & Delcea, C. (2025). Bibliometric Insights into Time Series Forecasting and AI Research: Growth, Impact, and Future Directions. *Applied Sciences*, 15(11), 6221. <https://doi.org/10.3390/app15116221>
14. Engle, R. F. (1982). *Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation*. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>
15. El-Diftar, D. (2023). The impact of exchange rates on stock market performance of the Emerging 7. *Journal of Capital Markets Studies*, 7(2), 125–139. <https://doi.org/10.1108/JCMS-03-2023-0005>
16. Estrella, A., & Mishkin, F. S. (1998). Predicting U.S. recessions: Financial variables as leading indicators. *The Review of Economics and Statistics*, 80(1), 45–61. <https://doi.org/10.1162/003465398557320>
17. Filgueira, F., y otros. (2020). *América Latina ante la crisis del COVID-19: vulnerabilidad socioeconómica y respuesta social* (Serie Políticas Sociales N° 238, LC/TS.2020/149). Comisión Económica para América Latina y el Caribe (CEPAL). <https://repositorio.cepal.org/handle/11362/46484>
18. Forbes, K. J., & Rigobon, R. (2002). No Contagion, Only Interdependence: Measuring Stock Market Comovements. *The Journal of Finance*, 57(5), 2223–2261. <https://www.jstor.org/stable/3094510>
19. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer. <https://link.springer.com/book/10.1007/978-0-387-84858-7>
20. Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
21. Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. <https://doi.org/10.1093/biomet/68.1.165>
22. Henrique, B. M., Sobreiro, V. A., & Kimura, H. (2019). Literature review: Machine

- learning techniques applied to financial market prediction. *Expert Systems with Applications*, 124, 226–251. <https://doi.org/10.1016/j.eswa.2019.01.012>
23. Kalange, D. N. (2025). Prediction of stock prices using LSTM-ARIMA hybrid deep learning model. *Asian Journal of Probability and Statistics*, 27(8), 28–39. <https://doi.org/10.9734/ajpas/2025/v27i8791>
 24. Karolyi, G. A., & Van Nieuwerburgh, S. (2020). New Methods for the Cross-Section of Returns. *The Review of Financial Studies*, 33(5), 1879–1890. <https://doi.org/10.1111/joes.70002>
 25. Kim, D., & Baek, J. G. (2022). Bagging ensemble-based novel data generation method for univariate time series forecasting. *Expert Systems with Applications*, 203, 117366. <https://doi.org/10.1016/j.eswa.2022.117366>
 26. Kim, B.-J., & Nam, I.-W. (2025). A Review of Hybrid LSTM Models in Smart Cities. *Processes*, 13(7), 2298. <https://doi.org/10.3390/pr13072298>
 27. Krause, T. A., & Tse, Y. (2016). Risk management and firm value: Recent theory and evidence. *International Journal of Accounting and Information Management*, 24(1), 56–81. <https://doi.org/10.1108/IJAIM-05-2015-0027>
 28. Lim, B., & Zohren, S. (2021). Time series forecasting with deep learning: A survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 379(2194), 20200209. <https://doi.org/10.1098/rsta.2020.0209>
 29. López de Prado, M. (2018). *Advances in Financial Machine Learning* (1st ed.). Wiley
 30. Lukanima, B., Sánchez-Barrios, E., & Gómez-Bravo, L. (2024). Towards understanding MILA stock markets integration beyond MILA. *The Quarterly Review of Economics and Finance*, 89, 478–497. <https://doi.org/10.1016/j.iref.2023.07.029>
 31. McNeil, A. J., Frey, R., & Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools* (Revised ed.). Princeton University Press. https://archive.org/download/quant_books/Quantitative%20Risk%20Management%20-%20A.%20J.%20McNeil%2C%20R.%20Frey.pdf
 32. Miranda-Agrippino, S., & Rey, H. (2022). The Global Financial Cycle. *NBER Working Paper No. 29327*. National Bureau of Economic Research. <https://doi.org/10.3386/w29327>
 33. Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370. <https://doi.org/10.1093/rfs/hhaa019>

34. Neumeyer, P. A., & Perri, F. (2005). Business cycles in emerging economies: The role of interest rates. *Journal of Monetary Economics*, 52(2), 345–380.
<https://doi.org/10.1016/j.jmoneco.2004.04.011>
35. Pandya, A., Kapoor, V., & Joshi, A. (2024). Stock market prediction using ARIMA-LSTM hybrid. *Journal of Information & Optimization Sciences*, 45(4), 1129–1139.
<https://doi.org/10.47974/JIOS-1697>
36. Pérez, C., & Briceño, M. (2015). Emerging markets integration in Latin America (MILA). *Journal of Economics, Finance and Administrative Science*, 20(39), 89–98.
<https://doi.org/10.1016/j.jefas.2015.01.003>
37. Rossi, B., & Sekhposyan, T. (2021). *Alternative tests for correct specification of conditional predictive densities*. *Journal of Econometrics*, 208(2), 638–657.
<https://econ-papers.upf.edu/papers/1711.pdf>
38. Sharpe, W. F. (1966). Mutual Fund Performance. *Journal of Business*, 39(1), 119-138.
<https://finance.martinsewell.com/fund-performance/Sharpe1966.pdf>
39. Shen, Y., Mercatoris, B., Cao, Z., Kwan, P., Guo, L., Yao, H., & Cheng, Q. (2022). Improving wheat yield prediction accuracy using LSTM-RF framework based on UAV thermal infrared and multispectral imagery. *Agriculture*, 12(6), 892.
<https://doi.org/10.3390/agriculture12060892>
40. Shi, C. (2025). From econometrics to machine learning: Transforming empirical asset pricing. Chinese University of Hong Kong, Shenzhen; Beijing Liangxin Investment Management Co. Ltd. SSRN. <https://doi.org/10.1111/joes.70002>
41. Stempień, D., & Ślepaczuk, R. (2025). Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models.
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5268691
42. Schuster, M., & Paliwal, K. K. (1997). *Bidirectional recurrent neural networks*. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681.
<https://doi.org/10.1109/78.650093>
43. Tsay, R. S. (2013). Multivariate time series analysis: with R and financial applications. John Wiley & Sons.
<https://www.wiley.com/en-us/Multivariate+Time+Series+Analysis%3A+With+R+and+Financial+Applications-p-9781118617908>
44. Troncoso R., J. (2025, 14 de marzo). Los factores que mantienen al IPSA con cifras récord (y el desplome de Wall Street). *Ex-Ante*.
<https://www.ex-ante.cl/los-factores-que-mantienen-al-ipsa-con-cifras-record-y->

el-desplome-de-wall-street/

45. Wilder, J. W. (1978). New Concepts in Technical Trading Systems. *Trend Research*.<https://archive.org/details/newconceptsintec00wild>
46. Yunita, A., Pratama, M. I., Almuzakki, M. Z., et al. (2025). Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models. *MethodsX*, 15, 103462.<https://doi.org/10.1016/j.mex.2025.103462>
47. Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159-175.[https://doi.org/10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0)
48. Zhou, J., & Zhang, H. (2018). A Hybrid Model Based on LSTM and Random Forest for Stock Market Prediction. *Proceedings of the 2018 International Conference on Machine Learning and Cybernetics*, 328–332.

Anexos

ANEXO A: Diagnóstico de Multicolinealidad (Matriz de Pearson)




Figura A.1: Matriz de correlación de Pearson aplicada a las variables transformadas mediante Diferenciación Fraccional (FFD) e indicadores de régimen estacionario.